

PLATAFORMA DE INTELIGÊNCIA DE MERCADO DE TRABALHO PARA PROFISSIONAIS DE TECNOLOGIA UTILIZANDO ARQUITETURA MEDALHÃO, AIRFLOW, PYTHON E POWER BI

Autor: Nathan Thomaz **Instituição:** Centro Universitário La Salle — Unilasalle

Curso: Sistemas de Informação **Trabalho de Conclusão de Curso** **Ano:** 2026

RESUMO

Este trabalho propõe a concepção e implementação de uma plataforma de inteligência de mercado de trabalho para profissionais de tecnologia, baseada na Arquitetura Medalhão (Bronze, Silver e Gold), com orquestração automatizada por Apache Airflow e visualização analítica via Microsoft Power BI. As fontes de dados são as APIs públicas da Adzuna (vagas de emprego) e do IBGE (dados geográficos e populacionais), integradas em um pipeline de Engenharia de Dados desenvolvido inteiramente em Python. A hipótese é operacionalizada por critérios mensuráveis: completude dos dados superior a 95%, consistência entre camadas superior a 98%, automação completa do pipeline via Airflow e capacidade analítica comprovada por ao menos cinco indicadores-chave de desempenho (KPIs) de mercado de trabalho em tecnologia disponíveis no Power BI. A metodologia classifica-se como pesquisa aplicada de natureza mista, com estudo de caso experimental. O trabalho contribui para demonstrar a viabilidade de pipelines modernos de Engenharia de Dados com dados reais de mercado, integração de múltiplas APIs públicas e orquestração profissional em cenário acadêmico.

Palavras-chave: Arquitetura Medalhão. Apache Airflow. Mercado de Trabalho. Engenharia de Dados. APIs Públicas. Power BI. Python. Qualidade de Dados.

CAPÍTULO 1 — INTRODUÇÃO

1.1 Motivação

A transformação digital acelerou profundamente o mercado de trabalho na área de tecnologia, gerando um fluxo contínuo e volumoso de dados sobre vagas de emprego, demanda por competências, distribuição geográfica de oportunidades e dinâmicas salariais. De acordo com o relatório do Fórum Econômico Mundial (2023), espera-se a criação de milhões de novos postos de trabalho em áreas como inteligência artificial, ciência de dados e engenharia de software nos

próximos anos, ao mesmo tempo em que outras funções tradicionais tendem a desaparecer ou se transformar. Nesse contexto, a capacidade de coletar, integrar e analisar dados sobre o mercado de trabalho de forma sistemática torna-se um diferencial estratégico para profissionais, instituições de ensino e organizações de recrutamento.

Embora existam plataformas comerciais de análise de mercado de trabalho, soluções abertas e aplicadas que demonstrem, de ponta a ponta, a construção de uma plataforma de inteligência de dados sobre o setor de tecnologia ainda são escassas na literatura acadêmica. A maioria dos trabalhos disponíveis aborda componentes isolados do problema — seja a extração de dados de uma única fonte, seja a construção de visualizações descritivas — sem integrar múltiplas fontes públicas de dados em uma arquitetura de Engenharia de Dados estruturada, governada e orientada a análises estratégicas.

A disponibilidade de APIs públicas, como a Adzuna para vagas de emprego e o IBGE para dados geográficos e populacionais, oferece uma oportunidade concreta para a construção de um ambiente analítico capaz de consolidar informações heterogêneas sobre o mercado de trabalho em tecnologia. A integração dessas fontes, por meio de uma Arquitetura Medalhão (Bronze, Silver e Gold), orquestrada com Apache Airflow e desenvolvida em Python, permite transformar dados públicos dispersos em informações estratégicas, acessíveis por meio de dashboards interativos no Power BI.

A relevância acadêmica do tema é reforçada pela escassez de implementações práticas que combinem orquestração de pipelines com Airflow, Arquitetura Medalhão e integração de APIs heterogêneas no contexto específico do mercado de trabalho em tecnologia — lacuna que este trabalho se propõe a preencher

1.2 Problema de Pesquisa

Como projetar e implementar uma plataforma de Engenharia de Dados capaz de coletar, integrar e disponibilizar informações de múltiplas APIs públicas sobre o mercado de trabalho em tecnologia, aplicando a Arquitetura Medalhão (Bronze, Silver e Gold) com orquestração via Apache Airflow, de forma a produzir análises estratégicas confiáveis e auditáveis sobre vagas de emprego, competências demandadas e distribuição geográfica das oportunidades?

1.3 Hipótese

A hipótese deste trabalho é que uma plataforma de Engenharia de Dados estruturada com a Arquitetura Medalhão, orquestrada por Apache Airflow e desenvolvida em Python, é capaz de integrar de forma confiável dados das APIs da Adzuna e do IBGE, produzindo indicadores analíticos consistentes e auditáveis sobre o mercado de trabalho em tecnologia. Para fins de verificação, a hipótese é considerada confirmada se, ao final da implementação, forem atendidos simultaneamente os seguintes critérios:

- **Completude dos dados** na camada Gold igual ou superior a **95%**, calculada como

proporção de campos obrigatórios preenchidos sobre o total esperado após a integração das fontes.

- **Consistência entre camadas** igual ou superior a **98%**, medida como proporção de

registros da camada Bronze que chegam íntegros à camada Gold após as transformações Silver, sem perda não justificada.

- **Automação completa do pipeline**, definida como a execução bem-sucedida de todas as

DAGs no Apache Airflow sem intervenção manual, incluindo reprocessamentos em caso de falha.

- **Capacidade analítica completa**, definida como a geração bem-sucedida de, no mínimo,

cinco indicadores estratégicos sobre o mercado de trabalho em tecnologia, disponíveis em dashboards interativos no Power BI com dados coerentes e auditáveis.

1.4 Objetivos

O objetivo geral deste trabalho é **projetar e implementar uma plataforma de inteligência de mercado de trabalho para profissionais de tecnologia**, utilizando a Arquitetura Medalhão (Bronze, Silver e Gold), orquestração com Apache Airflow, processamento em Python e visualização no Power BI.

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos:

- **Analisar** as principais características do mercado de trabalho em tecnologia e

identificar as fontes de dados públicas disponíveis — especialmente as APIs da Adzuna e do IBGE — para suporte às análises estratégicas propostas.

- **Projetar** a arquitetura da solução em camadas Bronze, Silver e Gold, definindo

os pipelines de ingestão, transformação e disponibilização dos dados, bem como o modelo analítico da camada Gold orientado aos indicadores de mercado.

- **Implementar** os pipelines de dados em Python, com ingestão das APIs da Adzuna e

do IBGE na camada Bronze, tratamento e enriquecimento na camada Silver, e estruturação analítica na camada Gold, garantindo rastreabilidade e qualidade em cada etapa.

- **Orquestrar** toda a execução dos pipelines por meio do Apache Airflow, automatizando

o agendamento, o controle de dependências, o monitoramento e o gerenciamento de falhas e reprocessamentos.

- **Avaliar** a solução por meio de métricas de completude ($\geq 95\%$), consistência entre

camadas ($\geq 98\%$) e capacidade analítica, verificando a geração dos indicadores estratégicos propostos nos dashboards do Power BI.

1.5 Organização do Trabalho

Este trabalho está estruturado em cinco capítulos, organizados de forma a conduzir o leitor desde a fundamentação teórica até os resultados e conclusões da pesquisa.

O **Capítulo 1** apresenta a introdução, compreendendo a motivação do trabalho, o problema de pesquisa, a hipótese formulada com critérios mensuráveis, os objetivos geral e específicos e a organização do documento.

O **Capítulo 2** desenvolve o referencial teórico, abordando os fundamentos de Big Data, as arquiteturas de armazenamento e processamento de dados (Data Lake, Data Warehouse e Arquitetura Medalhão), os princípios de Engenharia de Dados, orquestração de pipelines com Apache Airflow, qualidade e governança de

dados, além das principais ferramentas tecnológicas utilizadas no projeto.

O **Capítulo 3** descreve a metodologia adotada, incluindo a classificação da pesquisa, o ambiente de desenvolvimento, as fontes de dados utilizadas (Adzuna e IBGE), a arquitetura do pipeline de dados nas camadas Bronze, Silver e Gold, o modelo analítico da camada Gold, a orquestração com Airflow e o protocolo de avaliação com métricas e critérios de aceitação.

O **Capítulo 4** apresenta os resultados obtidos com a implementação da plataforma, incluindo a análise do pipeline de dados, os valores das métricas de qualidade, a validação dos indicadores estratégicos gerados no Power BI e a avaliação da solução de orquestração implementada.

O **Capítulo 5** apresenta as conclusões do trabalho, respondendo à hipótese formulada com base nos critérios mensuráveis definidos, discutindo as limitações da pesquisa e apontando direções para trabalhos futuros.

CAPÍTULO 2 — REFERENCIAL TEÓRICO

2.1 Big Data: Conceito e Características

O termo Big Data designa conjuntos de dados cuja dimensão, complexidade e velocidade de geração superam a capacidade dos sistemas de gerenciamento de dados convencionais para captura, armazenamento, gestão e análise (CHEN; MAO; LIU, 2014). A popularização do conceito remonta ao trabalho de Laney (2001), que caracterizou o fenômeno por três dimensões fundamentais — volume, velocidade e variedade —, modelo posteriormente expandido para incluir veracidade e valor, compondo o que a literatura denomina os cinco Vs do Big Data.

O **volume** refere-se à quantidade massiva de dados gerados continuamente por dispositivos, transações e interações digitais. A **velocidade** diz respeito à taxa de geração e ao tempo exigido para processamento e resposta. A **variedade** abrange a multiplicidade de formatos e fontes, incluindo dados estruturados, semiestruturados (JSON, XML) e não estruturados (imagens, vídeos, texto livre). A **veracidade** concerne à incerteza e à qualidade inerente aos dados em grande escala, enquanto o **valor** refere-se à capacidade de extrair inteligência útil para a tomada de decisão organizacional (CHEN; MAO; LIU, 2014).

No contexto do mercado de trabalho em tecnologia, todas essas dimensões se manifestam de forma intensa: plataformas de vagas geram grandes volumes de

anúncios, descrições de cargos, dados salariais e localizações provenientes de múltiplas fontes heterogêneas, exigindo infraestruturas de dados capazes de ingerir, armazenar e processar esse fluxo contínuo com confiabilidade e rastreabilidade (LANEY, 2001; CHEN; MAO; LIU, 2014).

2.2 Arquiteturas de Armazenamento e Processamento de Dados

2.2.1 Data Warehouse

O Data Warehouse (Armazém de Dados) é definido por Inmon (2002) como um conjunto de dados orientado por assunto, integrado, variante no tempo e não volátil, projetado para suporte à tomada de decisão gerencial. Nessa abordagem, os dados são extraídos de sistemas transacionais, transformados para um formato padronizado e carregados em um repositório centralizado — processo denominado ETL (Extração, Transformação e Carga).

A modelagem de dados no Data Warehouse é fundamentada nos princípios de Kimball e Ross (2013), que propõem a organização dos dados em esquemas dimensionais — notadamente o Star Schema (Esquema Estrela) e o Snowflake Schema —, estruturas otimizadas para consultas analíticas de alto desempenho. O Star Schema organiza os dados em uma tabela fato central, que registra métricas de negócio mensuráveis, circundada por tabelas dimensão que fornecem contexto descritivo às métricas (KIMBALL; ROSS, 2013).

Os Data Warehouses tradicionais apresentam vantagens reconhecidas: garantias de qualidade e consistência dos dados, desempenho elevado em consultas analíticas e maturidade tecnológica consolidada. Contudo, suas limitações tornam-se evidentes em cenários de Big Data: o esquema rígido definido na ingestão dificulta a adaptação a novas fontes de dados, a escalabilidade predominantemente vertical impõe custos crescentes, e a separação entre dados brutos e processados cria silos que dificultam a rastreabilidade (INMON, 2002; STONEBRAKER; ÇETINTEMEL, 2005).

Soluções modernas de Data Warehouse em nuvem — como Snowflake, Google BigQuery e Amazon Redshift — mitigaram parte dessas limitações por meio de escalabilidade elástica e modelos de custo por uso. No entanto, introduzem dependência de fornecedor, custos significativos para armazenamento de dados brutos e semiestruturados, e integração limitada com fluxos de aprendizado de máquina e processamento em tempo real (DRECHSLER; SAUER, 2023).

2.2.2 Data Lake

O Data Lake (Lago de Dados) surgiu como resposta às limitações dos Data Warehouses tradicionais diante da explosão de volumes e variedades de dados. Conceitualmente, é um repositório centralizado que armazena dados em seu formato nativo e bruto — estruturados, semiestruturados e não estruturados —, sem a necessidade de definição de esquema no momento da ingestão. Essa abordagem, denominada schema-on-read, posterga a definição da estrutura para o momento do consumo, conferindo máxima flexibilidade (FANG, 2015).

As principais vantagens do Data Lake incluem o custo reduzido de armazenamento em sistemas de arquivos distribuídos, a capacidade de preservar dados brutos para reprocessamento futuro e a flexibilidade para acomodar diferentes tipos de carga analítica. Entretanto, sem governança, processos de qualidade e controle de acesso adequados, os Data Lakes tendem a se degradar em repositórios de dados desorganizados, sem catalogação e de difícil consumo analítico — fenômeno conhecido como pântano de dados. Essa deterioração decorre da ausência de garantias transacionais, da falta de versionamento e da dificuldade em aplicar atualizações e exclusões em arquivos imutáveis (FANG, 2015; ZAHARIA et al., 2021).

2.2.3 Arquitetura Medalhão

A Arquitetura Medalhão, amplamente adotada em implementações modernas de Engenharia de Dados e descrita pela Databricks (2023), representa um padrão de refinamento progressivo dos dados organizado em três camadas — Bronze, Silver e Gold —, cada uma com um nível crescente de qualidade, estruturação e prontidão para consumo analítico.

Diferentemente da arquitetura Lakehouse, que enfatiza os mecanismos de armazenamento transacional (como o Delta Lake), a Arquitetura Medalhão é um **padrão de design de pipeline de dados**, agnóstico quanto à tecnologia de armazenamento, e pode ser implementada com formatos como JSON, Parquet e CSV, orquestrada por ferramentas como o Apache Airflow. A separação clara entre camadas permite rastreabilidade completa, reprocessamento controlado e governança granular dos dados.

Essa arquitetura possibilita a unificação do ciclo de vida dos dados — desde a ingestão bruta até a análise estratégica — reduzindo redundâncias, custos operacionais e inconsistências decorrentes da movimentação não controlada entre sistemas distintos (DATABRICKS, 2023).

2.2.4 Quadro Comparativo das Arquiteturas

O Quadro 1 sintetiza as principais características das três arquiteturas discutidas, permitindo a visualização objetiva das diferenças e complementaridades entre elas.

Quadro 1 — Comparativo entre Data Warehouse, Data Lake e Arq. Medalhão

Característica	Data Warehouse	Data Lake	Arq. Medalhão
Definição de esquema	Na ingestão (schema-on-write)	No consumo (schema-on-read)	Na ingestão com evolução controlada
Tipos de dados suportados	Estruturados	Todos	Todos
Garantias ACID	Sim (banco relacional)	Não	Opcional (por tecnologia)
Custo de armazenamento	Alto	Baixo	Baixo
Escalabilidade	Vertical	Horizontal	Horizontal
Desempenho analítico	Alto	Variável	Alto
Transformações progressivas	Não	Não	Sim (Bronze→Silver→Gold)
Rastreabilidade	Limitada	Baixa	Total (por camada)
Orquestração	Processo ETL externo	Nenhuma	Airflow/DAGs

Fonte: elaborado pelo autor com base em Databricks (2023), Fang (2015) e Vassiliadis (2009).

2.3 Arquitetura em Camadas: Bronze, Silver e Gold

A organização dos dados em camadas é um padrão arquitetural amplamente adotado em implementações de Lakehouse e Engenharia de Dados moderna. O modelo de três camadas — Bronze, Silver e Gold —, descrito por Databricks (2023) e amplamente adotado em implementações de Engenharia de Dados moderna, estrutura o fluxo de dados de acordo com seu grau de refinamento e propósito de uso.

A **camada Bronze** recebe os dados em seu estado bruto, diretamente das fontes de origem, sem transformações. Seu propósito é preservar o histórico completo dos dados ingeridos, garantindo rastreabilidade e a possibilidade de reprocessamento a partir do ponto de origem. No contexto deste projeto, os dados

são provenientes das APIs Adzuna e IBGE, armazenados em formato JSON com metadados de ingestão.

A **camada Silver** representa a fase de refinamento dos dados. Nela são aplicados processos de limpeza, padronização de formatos, remoção de duplicatas, validação de integridade referencial, integração entre fontes e enriquecimento com informações complementares. O resultado é um conjunto de dados confiável, consistente e pronto para consumo por diferentes fluxos analíticos.

A **camada Gold** é a camada analítica da arquitetura. Os dados, já tratados e validados, são organizados em tabelas otimizadas para geração de indicadores de mercado de trabalho e alimentação de ferramentas de visualização como o Power BI (DATABRICKS, 2023; VASSILIADIS, 2009). Essa separação em camadas promove isolamento de falhas, controle de qualidade progressivo, rastreabilidade completa do ciclo de vida do dado e flexibilidade para que diferentes equipes consumam os dados no nível adequado às suas necessidades.

2.4 Engenharia de Dados e Pipelines de Transformação

A Engenharia de Dados é a disciplina responsável pelo projeto, construção e manutenção de infraestruturas e pipelines que permitem a coleta, o armazenamento, o processamento e a disponibilização de dados para consumo analítico e científico (VASSILIADIS, 2009). No contexto de arquiteturas modernas, dois paradigmas de transformação de dados se destacam: ETL e ELT.

No modelo tradicional **ETL** (Extração, Transformação e Carga), os dados são extraídos das fontes, transformados em um ambiente intermediário e somente então carregados no destino analítico. Esse modelo é adequado quando o sistema de destino tem capacidade de armazenamento limitada ou quando a transformação requer lógica complexa que não pode ser executada no ambiente de destino.

No modelo **ELT** (Extração, Carga e Transformação), predominante em arquiteturas modernas de Big Data, os dados são primeiramente carregados no sistema de destino em seu formato bruto e transformados posteriormente, aproveitando a capacidade de processamento do próprio ambiente analítico (VASSILIADIS, 2009). Esse modelo é natural na Arquitetura Medalhão, onde a camada Bronze recebe os dados brutos das APIs e as transformações são aplicadas progressivamente nas camadas Silver e Gold.

2.5 Orquestração de Pipelines com Apache Airflow

A orquestração de pipelines de dados é a prática de automatizar e coordenar a execução de múltiplas tarefas interdependentes de processamento de dados, garantindo que cada etapa seja executada na ordem correta, no momento certo e com os mecanismos adequados de monitoramento e recuperação de falhas (HARENSLAK; RUITER, 2021).

O Apache Airflow, criado pela Airbnb em 2014 e incubado pela Apache Software Foundation a partir de 2016, tornou-se a ferramenta de orquestração de pipelines mais adotada no ecossistema de Engenharia de Dados. Seu principal conceito é o de **DAG** (Directed Acyclic Graph — Grafo Acíclico Dirigido): uma estrutura que define as tarefas do pipeline e suas dependências de forma explícita, garantindo ordem de execução determinística.

As principais características do Airflow relevantes para este trabalho são:

- **Agendamento:** as DAGs podem ser agendadas para execução periódica (diária, semanal

etc.), automatizando a atualização dos dados sem intervenção manual.

- **Controle de dependências:** cada tarefa só é executada após o sucesso de suas

predecessoras, garantindo integridade do pipeline.

- **Monitoramento:** o Airflow Web UI fornece visibilidade em tempo real sobre o

estado de cada execução e logs detalhados por tarefa.

- **Retry automático e alertas:** em caso de falha, o Airflow pode retornar

automaticamente e enviar notificações por e-mail (APACHE AIRFLOW, 2024).

2.6 Qualidade e Governança de Dados

A qualidade de dados é um atributo multidimensional que reflete o grau em que um conjunto de dados atende aos requisitos de uso para os quais foi coletado ou produzido. Vassiliadis (2009) identifica as principais dimensões de qualidade relevantes para sistemas analíticos:

- **Completeness:** proporção de valores preenchidos em relação aos esperados.

- **Consistência:** ausência de contradições entre registros de uma mesma tabela ou

entre tabelas relacionadas.

- **Acurácia:** conformidade dos valores registrados com os valores reais que representam.

- **Unicidade:** ausência de registros duplicados que possam distorcer análises.

- **Pontualidade:** disponibilidade dos dados no momento em que são necessários.

Na Arquitetura Medalão, a qualidade de dados é gerenciada progressivamente entre as camadas: na camada Bronze os dados são ingeridos sem filtros; na Silver são aplicadas regras de validação e limpeza; e na Gold os dados atendem a um padrão de qualidade estabelecido para consumo analítico (DATABRICKS, 2023). A **governança de dados** nesse contexto inclui: controle de versões dos scripts de transformação, logs de execução registrados pelo Airflow, documentação das regras de transformação por camada e monitoramento de KPIs de qualidade do pipeline.

2.7 Ferramentas e Tecnologias

2.7.1 Python

Python é uma linguagem de programação de alto nível, interpretada e de propósito geral, que se tornou a linguagem dominante nos domínios de Engenharia de Dados, Ciência de Dados e Inteligência Artificial (RAMALHO, 2022). Sua sintaxe expressiva, vasto ecossistema de bibliotecas e ampla adoção comunitária tornam-na a escolha preferencial para construção de pipelines de dados modernos.

Neste trabalho, Python é utilizado como linguagem única em todo o pipeline:

- Biblioteca `requests` para consumo das APIs Adzuna e IBGE via HTTP
- Biblioteca `pandas` para manipulação, limpeza e transformação dos dados
- Biblioteca `json` para serialização e desserialização dos dados da camada Bronze
- Definição das **DAGs do Airflow** como scripts Python

2.7.2 Apache Airflow

O Apache Airflow é a principal ferramenta de orquestração de pipelines de dados de código aberto da atualidade, com ampla adoção em ambientes corporativos e acadêmicos. Seu design baseado em DAGs Python permite que os engenheiros de dados descrevam pipelines complexos como código, versionando, testando e documentando os fluxos de trabalho com as mesmas práticas de desenvolvimento de software (HARENSLAK; RUITER, 2021). Neste projeto, o Airflow é executado via Docker Compose e responsável pelo agendamento e monitoramento de todas as DAGs do pipeline.

2.7.3 Microsoft Power BI

O Microsoft Power BI é uma plataforma de Inteligência de Negócios voltada para a criação de relatórios e painéis interativos. Utilizado como camada de consumo da camada Gold da Arquitetura Medalhão, o Power BI transforma os dados analíticos sobre o mercado de trabalho em tecnologia em visualizações acessíveis a usuários de negócio. Sua integração nativa com arquivos Parquet e conexão direta a pastas de dados torna-o adequado para validar os indicadores do pipeline proposto (MICROSOFT, 2023).

2.7.4 APIs Públicas: Adzuna e IBGE

As APIs públicas são interfaces que permitem o acesso programático a dados e funcionalidades de terceiros por meio do protocolo HTTP. A **API da Adzuna** é uma fonte de dados de vagas de emprego global, que exposta dados estruturados sobre títulos de cargos, empresas, localizações, descrições e salários (ADZUNA, 2024). A **API do IBGE** oferece acesso a dados geográficos, populacionais e econômicos do Brasil, permitindo enriquecer as análises de vagas com contexto regional (IBGE, 2024). A integração dessas fontes heterogêneas constitui o núcleo da proposta deste trabalho.

CAPÍTULO 3 — METODOLOGIA

3.1 Classificação da Pesquisa

Do ponto de vista de sua natureza, este trabalho configura-se como uma **pesquisa aplicada**, pois objetiva a geração de conhecimento voltado à solução de um problema prático e concreto: a construção de uma plataforma de Engenharia de Dados funcional para inteligência de mercado de trabalho em tecnologia (GIL, 2002). Quanto aos seus objetivos, classifica-se como **exploratório-descritiva**: exploratória pela relativa escassez de estudos aplicados que combinem

Arquitetura Medalhão, orquestração com Airflow e integração de múltiplas APIs públicas no domínio de mercado de trabalho; descritiva por registrar sistematicamente as características do pipeline implementado e seus resultados mensuráveis.

Em relação à abordagem do problema, a pesquisa é **mista (quali-quantitativa)**: adota instrumentos quantitativos para coleta e análise de métricas de qualidade de dados e de desempenho dos pipelines, e abordagem qualitativa para avaliação da adequação da arquitetura proposta ao problema de inteligência de mercado. Quanto ao procedimento técnico, enquadra-se como **estudo de caso experimental**, pois implementa um sistema de software completo — desde a extração das APIs até a camada analítica — e avalia seus resultados em condições controladas (YIN, 2015).

3.2 Ambiente de Desenvolvimento

A implementação deste trabalho é realizada em ambiente local com as seguintes especificações:

Hardware:

- Sistema Operacional: Microsoft Windows 11 Pro
- Processador: compatível com execução de containers Docker
- Memória RAM: mínimo 8 GB

Software e versões:

Ferramenta	Versão	Finalidade
Python	3.11	Linguagem principal do projeto
Apache Airflow	2.9	Orquestração dos pipelines
Pandas	2.2	Manipulação de dados tabulares
Requests	2.31	Consumo das APIs externas
Docker	26+	Execução do ambiente Airflow
Power BI Desktop	Versão atual	Camada de visualização analítica
API Adzuna	v1	Fonte de vagas de emprego
API IBGE	v3	Fonte de dados geográficos e populacionais

O Apache Airflow é executado via **Docker Compose**, utilizando a imagem oficial da Apache, o que garante portabilidade e reprodutibilidade do ambiente de desenvolvimento.

3.3 Fontes de Dados

O projeto utiliza APIs públicas como fontes primárias de dados, permitindo a integração de diferentes contextos de informação sobre o mercado de trabalho em tecnologia.

3.3.1 API Adzuna — Vagas de Emprego

A API da Adzuna é a principal fonte de dados do projeto, fornecendo informações sobre vagas de emprego publicadas no mercado, incluindo cargos, empresas, localizações, descrições e informações salariais quando disponíveis. O acesso é realizado mediante cadastro e obtenção de chave de API (app_id e app_key).

Quadro 3 — Endpoints da API Adzuna utilizados

Método	Endpoint	Retorno
GET	/api/v1/{country}/search/{page}	Lista de vagas com paginação
GET	/api/v1/{country}/categories	Categorias de vagas disponíveis
GET	/api/v1/{country}/histogram	Distribuição salarial por categoria

Fonte: Adzuna (2024).

3.3.2 API IBGE — Dados Geográficos e Populacionais

Os serviços do IBGE fornecem dados complementares sobre estados, municípios, regiões e indicadores populacionais, enriquecendo as análises geográficas e permitindo correlacionar o volume de vagas com a população de cada localidade.

Quadro 4 — Endpoints da API IBGE utilizados

Método	Endpoint	Retorno
GET	/api/v3/localidades/estados	Lista de estados brasileiros

Método	Endpoint	Retorno
GET	/api/v3/localidades/municipios	Lista de municípios
GET	/api/v3/agregados/{id}/...	Indicadores populacionais

Fonte: IBGE (2024).

3.4 Arquitetura do Pipeline de Dados

O pipeline de dados é implementado seguindo o padrão de três camadas da Arquitetura Medalhão, orquestrado pelo Apache Airflow por meio de DAGs dedicadas para cada fonte de dados.

3.4.1 Camada Bronze — Ingestão Bruta

A camada Bronze realiza a ingestão dos dados diretamente das APIs Adzuna e IBGE, sem nenhuma transformação. Os dados são armazenados em formato JSON particionado por data de ingestão, com metadados de rastreabilidade (`_data_ingestao`, `_origem`), em `data/raw/bronze/{fonte}/`.

3.4.2 Camada Silver — Refinamento e Qualidade

A camada Silver aplica regras de qualidade e padronização sobre os dados da camada Bronze. As transformações incluem: remoção de duplicatas por chave de negócio; preenchimento ou exclusão de registros com campos obrigatórios nulos; validação de domínio (datas válidas, tipos corretos); padronização e normalização de strings; extração de habilidades técnicas a partir das descrições das vagas; e integração com dados geográficos do IBGE. Saída em formato Parquet em `data/processed/silver/{fonte}/`.

3.4.3 Camada Gold — Modelo Analítico

A camada Gold organiza os dados refinados em tabelas analíticas otimizadas para consumo pelo Power BI, respondendo diretamente aos indicadores de mercado de trabalho definidos na hipótese. Gravação em formato Parquet em `data/analytical/gold/{tabela}/`.

3.5 Modelo Analítico — Camada Gold

O modelo analítico implementado na camada Gold é composto por tabelas orientadas a indicadores de mercado de trabalho em tecnologia.

Quadro 5 — Tabela: vagas

Coluna	Tipo	Descrição
id_vaga	STRING	Identificador único da vaga
titulo	STRING	Título do cargo
empresa	STRING	Nome da empresa anunciante
uf	STRING	Unidade Federativa
regiao	STRING	Região geográfica
salario_min	DECIMAL(10,2)	Salário mínimo anunciado
salario_max	DECIMAL(10,2)	Salário máximo anunciado
data_publicacao	DATE	Data de publicação
categoria	STRING	Categoria de emprego

As demais tabelas analíticas são: **habilidades** (id, id_vaga, habilidade, categoria_skill), **localizacao** (uf, nome_estado, regiao, populacao, total_vagas, vagas_por_100k_hab) e **tendencias_mensais** (ano_mes, categoria, total_vagas, salario_medio).

3.6 Orquestração com Apache Airflow

O Apache Airflow é responsável por automatizar, agendar e monitorar todos os pipelines da plataforma. Cada camada da Arquitetura Medalhão possui uma DAG dedicada.

Quadro 6 — DAGs implementadas

DAG	Fonte	Periodicidade	Descrição
dag_bronze_adzuna	Adzuna API	Diária	Coleta de vagas
dag_bronze_ibge	IBGE API	Semanal	Coleta de dados geográficos
dag_silver_transform	Bronze	Diária	Limpeza e integração
dag_gold_analytics	Silver	Diária	Geração das tabelas analíticas

Mecanismos de controle incluem: retentativas automáticas (até 3), alertas por e-mail, logs detalhados no Airflow Web UI e dependências explícitas entre DAGs.

3.7 Protocolo de Avaliação

3.7.1 Métricas de Qualidade de Dados

3.7 Protocolo de Avaliação

A avaliação da plataforma proposta será conduzida por meio de métricas objetivas, aplicadas em duas dimensões: qualidade dos dados e capacidade analítica.

3.7.1 Métricas de Qualidade de Dados

Quadro 7 — Métricas de qualidade e critérios de aceitação

Métrica	Fórmula	Critério
Compleitude	$\text{registros_completos} / \text{total_esperado} \times 100$	$\geq 95\%$
Consistência	$\text{registros_íntegros} / \text{total_bronze} \times 100$	$\geq 98\%$
Unicidade	$(\text{total} - \text{duplicatas}) / \text{total} \times 100$	$= 100\%$
Acurácia de tipos	$\text{campos_tipados_corretamente} / \text{total} \times 100$	$= 100\%$

Fonte: elaborado pelo autor.

3.7.2 Indicadores de Mercado de Trabalho Avaliados

1. Evolução do volume de vagas ao longo do tempo (mensal/trimestral) 2. Distribuição geográfica das oportunidades por UF e região 3. Empresas com maior volume de vagas publicadas 4. Tecnologias e habilidades mais demandadas 5. Indicadores salariais por cargo e região

Cada indicador é considerado **válido** quando: (a) atualiza automaticamente após execução do pipeline; (b) os valores são coerentes com os dados originais das APIs (verificação por amostragem); e (c) o painel produz resultado em tempo adequado para uso interativo no Power BI Desktop.

3.8 Cronograma de Execução

Quadro 8 — Cronograma do projeto

Etapa	Atividade	Período
1	Revisão bibliográfica e fundamentação teórica	Março 2026
2	Configuração do ambiente e autenticação nas APIs	Março 2026
3	Implementação das DAGs Bronze (Adzuna e IBGE)	Abril 2026
4	Implementação da camada Silver (limpeza e integração)	Abril 2026
5	Implementação da camada Gold (modelo analítico)	Maio 2026
6	Configuração da orquestração completa no Airflow	Maio 2026
7	Desenvolvimento do painel Power BI	Junho 2026
8	Coleta e análise das métricas de avaliação	Junho 2026
9	Redação dos capítulos de resultados e conclusões	Julho 2026
10	Revisão final e entrega do TCC	Agosto 2026

Fonte: elaborado pelo autor.

REFERÊNCIAS BIBLIOGRÁFICAS

ADZUNA. **API Documentation**. Disponível em: . Acesso em: 2024.

APACHE AIRFLOW. **Apache Airflow Documentation**. Disponível em: . Acesso em: 2024.

CHEN, Min; MAO, Shiwen; LIU, Yunhao. **Big Data: A Survey**. Mobile Networks and Applications, v. 19, n. 2, p. 171–209, 2014.

DATABRICKS. **Medallion Architecture**. Databricks Documentation, 2023.

FANG, Hu. **Managing Data Lakes in Big Data Era: What's a Data Lake and Why Has It Become Popular in Data Management Ecosystem**. In: IEEE International Conference on Cyber Technology in Automation, Control, and Intelligent Systems (CYBER), 2015.

FÓRUM ECONÔMICO MUNDIAL. **The Future of Jobs Report 2023**. Genebra: World Economic Forum, 2023.

GIL, Antonio Carlos. **Como elaborar projetos de pesquisa**. 6. ed. São Paulo: Atlas, 2002.

HARENSLAK, Bas; RUITER, Julian de. **Data Pipelines with Apache Airflow**. Manning Publications, 2021.

IBGE — INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **API IBGE Serviços**. Disponível em: . Acesso em: 2024.

INMON, William H. **Building the Data Warehouse**. 4. ed. Nova York: John Wiley & Sons, 2002.

LANEY, Doug. **3D Data Management: Controlling Data Volume, Velocity, and Variety**. META Group Research Note, 2001.

MICROSOFT. **Power BI Documentation**. Microsoft Docs, 2023.

RAMALHO, Luciano. **Python Fluente**. 2. ed. São Paulo: O'Reilly / Novatec, 2022.

VASSILIADIS, Panos. **A Survey of Extract-Transform-Load Technology**. International Journal of Data Warehousing and Mining, v. 5, n. 3, p. 1–27, 2009.

YIN, Robert K. **Estudo de caso: planejamento e métodos**. 5. ed. Porto Alegre: Bookman, 2015.