

CENTRO UNIVERSITÁRIO LA SALLE — UNILASALLE

Curso de Sistemas de Informação

IMPLEMENTAÇÃO DE UMA ARQUITETURA LAKEHOUSE COM CAMADAS BRONZE, SILVER E GOLD PARA ANÁLISE DE DADOS DE E-COMMERCE

Autor: Nathan Thomaz

Trabalho de Conclusão de Curso

2026

RESUMO

Este trabalho propõe a implementação de uma arquitetura Lakehouse estruturada em camadas Bronze, Silver e Gold, utilizando tecnologias abertas como Apache Spark e Delta Lake, aplicada a dados simulados de comércio eletrônico. O objetivo é avaliar se essa abordagem constitui uma alternativa viável, escalável e de baixo custo ao Armazém de Dados tradicional, mantendo qualidade analítica equivalente para geração de indicadores de negócio. A hipótese é operacionalizada por critérios mensuráveis: completude dos dados superior a 95%, consistência entre camadas superior a 98% e latência de consulta analítica inferior ou igual a 1,5 vezes a do modelo de referência PostgreSQL. A camada Ouro (Gold) implementa um modelo dimensional Esquema Estrela (Star Schema) alimentando painéis interativos no Power BI como instrumento de validação analítica. A metodologia classifica-se como pesquisa aplicada de natureza mista, com estudo de caso experimental. O trabalho contribui para preencher a lacuna de estudos aplicados que demonstrem pipelines completos de Engenharia de Dados com validação empírica em cenários de comércio eletrônico.

Palavras-chave: Lakehouse. Big Data. Engenharia de Dados. Armazém de Dados. Delta Lake. Apache Spark. Modelagem Dimensional. Qualidade de Dados.

SUMÁRIO

1 INTRODUÇÃO

- 1.1 Motivação
- 1.2 Problema de Pesquisa
- 1.3 Hipótese
- 1.4 Objetivos
- 1.5 Organização do Trabalho

2 REFERENCIAL TEÓRICO

- 2.1 Big Data: Conceito e Características
- 2.2 Arquiteturas de Armazenamento e Processamento de Dados
 - 2.2.1 Armazém de Dados (Data Warehouse)
 - 2.2.2 Lago de Dados (Data Lake)
 - 2.2.3 Arquitetura Lakehouse
 - 2.2.4 Quadro Comparativo das Arquiteturas
- 2.3 Arquitetura em Camadas: Bronze, Silver e Gold
- 2.4 Engenharia de Dados e Pipelines de Transformação
- 2.5 Modelagem Dimensional
- 2.6 Qualidade de Dados
- 2.7 Ferramentas e Tecnologias
 - 2.7.1 Apache Spark
 - 2.7.2 Delta Lake
 - 2.7.3 Microsoft Power BI

3 METODOLOGIA

- 3.1 Classificação da Pesquisa
- 3.2 Ambiente de Desenvolvimento
- 3.3 Especificação do Conjunto de Dados Simulado
- 3.4 Arquitetura do Pipeline de Dados
- 3.5 Modelo Dimensional — Esquema Estrela
- 3.6 Modelo de Referência — Armazém de Dados Convencional
- 3.7 Protocolo de Avaliação
- 3.8 Cronograma de Execução

REFERÊNCIAS BIBLIOGRÁFICAS

CAPÍTULO 1 — INTRODUÇÃO

1.1 Motivação

O crescimento acelerado do comércio eletrônico nas últimas décadas tem produzido volumes massivos de dados transacionais — pedidos, clientes, produtos, pagamentos e interações — que representam um ativo estratégico para a tomada de decisão empresarial. De acordo com Armbrust et al. (2021), a capacidade de armazenar, processar e analisar grandes volumes de dados de forma eficiente tornou-se um diferencial competitivo fundamental para organizações orientadas a dados. Nesse contexto, arquiteturas de dados modernas surgem como resposta à crescente demanda por análises ágeis e de baixo custo operacional.

Historicamente, os Armazéns de Dados (Data Warehouses) tradicionais, fundamentados nas propostas de Inmon (2002) e Kimball e Ross (2013), consolidaram-se como a principal solução para armazenamento e análise de dados estruturados em ambientes corporativos. Essas arquiteturas, no entanto, foram concebidas em um contexto tecnológico distinto do atual, no qual o volume, a variedade e a velocidade dos dados eram substancialmente menores. Com o advento do Big Data, caracterizado por Laney (2001) pelas dimensões de volume, velocidade e variedade, os Armazéns de Dados tradicionais passaram a apresentar limitações estruturais significativas: dependência de infraestrutura proprietária de alto custo, esquemas de dados rígidos definidos no momento da ingestão e escalabilidade predominantemente vertical (INMON, 2002).

Embora soluções modernas de Armazém de Dados em nuvem, como Snowflake, Google BigQuery e Amazon Redshift, tenham mitigado parte dessas limitações, elas introduzem novas dependências de fornecedores, custos elevados para armazenamento de dados brutos e dificuldades de integração com fluxos de aprendizado de máquina (STONEBRAKER; ÇETINTEMEL, 2005; ZAHARIA et al., 2016). Drechsler e Sauer (2023) observam que, mesmo em ambientes de nuvem, o custo total de propriedade tende a ser elevado para organizações de pequeno e médio porte quando os dados crescem exponencialmente.

Diante dessas limitações, o conceito de Lago de Dados (Data Lake) emergiu como alternativa, propondo o armazenamento de dados em formato bruto a baixo custo. Contudo, sem governança adequada, os Lagos de Dados tendem a se degradar em repositórios desorganizados — fenômeno conhecido como pântano de dados (FANG, 2015). A arquitetura Lakehouse, proposta por Armbrust et al. (2021), surge para endereçar

essa dualidade, combinando a flexibilidade e o baixo custo dos Lagos de Dados com as garantias de qualidade e desempenho analítico dos Armazéns de Dados.

A relevância acadêmica do tema é reforçada pela escassez de estudos aplicados que demonstrem, de forma prática e mensurável, a implementação de arquiteturas Lakehouse voltadas ao domínio do comércio eletrônico — lacuna que este trabalho se propõe a preencher, por meio de um pipeline completo com validação empírica da qualidade analítica (ZAHARIA et al., 2021).

O presente trabalho propõe a implementação de uma arquitetura Lakehouse estruturada em camadas Bronze, Silver e Gold, utilizando Apache Spark e Delta Lake, aplicada a dados simulados de comércio eletrônico, visando demonstrar sua viabilidade como alternativa escalável e de baixo custo ao Armazém de Dados tradicional.

1.2 Problema de Pesquisa

Em que medida uma arquitetura Lakehouse com camadas Bronze, Silver e Gold, implementada com tecnologias abertas, é capaz de atender às demandas de escalabilidade e custo-benefício para análise de dados de comércio eletrônico, mantendo nível de qualidade analítica comparável ao oferecido por soluções de Armazém de Dados para a geração de indicadores de negócio?

1.3 Hipótese

A hipótese deste trabalho é que a arquitetura Lakehouse, implementada com Apache Spark e Delta Lake em camadas Bronze, Silver e Gold, oferece melhor relação custo-benefício e escalabilidade horizontal em comparação ao modelo tradicional de Armazém de Dados, mantendo qualidade analítica equivalente. Para fins de verificação empírica, a hipótese é considerada confirmada se forem atendidos simultaneamente os seguintes critérios:

- **Completeness dos dados** na camada Gold igual ou superior a **95%** (proporção de campos obrigatórios preenchidos sobre o total esperado).
- **Consistência entre camadas** igual ou superior a **98%** (proporção de registros da camada Bronze que chegam íntegros à camada Gold, sem perda não justificada).
- **Latência de consulta analítica** na camada Gold inferior ou igual a **1,5 vezes** a latência das mesmas consultas no Armazém de Dados de referência (PostgreSQL com Esquema Estrela equivalente).
- **Capacidade analítica completa:** geração bem-sucedida dos cinco indicadores de negócio no Power BI, com resultados coerentes com o conjunto de dados simulado e idênticos aos do Armazém de Dados de referência.

1.4 Objetivos

O objetivo geral deste trabalho é **implementar uma arquitetura Lakehouse com camadas Bronze, Silver e Gold para análise de dados de comércio eletrônico**, avaliando sua viabilidade como alternativa escalável e de baixo custo frente ao Armazém de Dados tradicional.

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos:

- **Analisar** as limitações dos Armazéns de Dados tradicionais e modernos, considerando custo, escalabilidade, flexibilidade de esquema e dependência de fornecedor, com base em revisão teórica comparativa.
- **Projetar** o modelo dimensional Esquema Estrela para suporte à análise de indicadores de vendas, clientes e produtos na camada Gold, definindo tabelas fato e dimensões alinhadas ao domínio de comércio eletrônico.
- **Implementar** o pipeline de dados nas camadas Bronze, Silver e Gold utilizando Apache Spark e Delta Lake, com ingestão a partir de uma interface de programação simulada, garantindo rastreabilidade, versionamento e qualidade dos dados.
- **Avaliar** a arquitetura por meio das métricas de completude ($\geq 95\%$), consistência ($\geq 98\%$) e latência de consulta ($\leq 1,5\times$ o Armazém de Dados de referência), comparando com um modelo PostgreSQL equivalente e validando nos painéis do Power BI.

1.5 Organização do Trabalho

Este trabalho está estruturado em cinco capítulos. O **Capítulo 1** apresenta a introdução com motivação, problema, hipótese mensurável, objetivos e organização. O **Capítulo 2** desenvolve o referencial teórico sobre Big Data, arquiteturas de dados, Engenharia de Dados, modelagem dimensional, qualidade de dados e ferramentas. O **Capítulo 3** descreve a metodologia, com classificação da pesquisa, ambiente, conjunto de dados simulado, pipeline, modelo dimensional, Armazém de Dados de referência e protocolo de avaliação. O **Capítulo 4** apresentará os resultados e a comparação empírica. O **Capítulo 5** apresentará as conclusões respondendo à hipótese formulada.

CAPÍTULO 2 — REFERENCIAL TEÓRICO

2.1 Big Data: Conceito e Características

O termo Big Data designa conjuntos de dados cuja dimensão, complexidade e velocidade de geração superam a capacidade dos sistemas de gerenciamento convencionais (CHEN; MAO; LIU, 2014). Laney (2001) caracterizou o fenômeno por três dimensões fundamentais — volume, velocidade e variedade —, modelo expandido para incluir veracidade e valor, compondo os cinco Vs do Big Data.

O **volume** refere-se à quantidade massiva de dados gerados por dispositivos, transações e interações digitais. A **velocidade** diz respeito à taxa de geração e ao tempo exigido para processamento. A **variedade** abrange dados estruturados, semiestruturados (JSON, XML) e não estruturados (imagens, vídeos, texto). A **veracidade** concerne à qualidade inerente aos dados em grande escala, enquanto o **valor** refere-se à extração de inteligência útil para a tomada de decisão (CHEN; MAO; LIU, 2014). No contexto do comércio eletrônico, todas essas dimensões se manifestam de forma intensa, exigindo infraestruturas capazes de ingerir, armazenar e processar fluxos contínuos com baixa latência (ARMBRUST et al., 2021).

2.2 Arquiteturas de Armazenamento e Processamento de Dados

2.2.1 Armazém de Dados (Data Warehouse)

O Armazém de Dados é definido por Inmon (2002) como um conjunto de dados orientado por assunto, integrado, variante no tempo e não volátil, projetado para suporte à tomada de decisão gerencial. Os dados são extraídos de sistemas transacionais, transformados e carregados em um repositório centralizado — processo denominado ETL (Extração, Transformação e Carga). A modelagem dimensional, fundamentada em Kimball e Ross (2013), propõe esquemas como o Esquema Estrela, que organiza os dados em uma tabela fato central circundada por tabelas dimensão.

Os Armazéns de Dados tradicionais apresentam vantagens reconhecidas: consistência, desempenho analítico e maturidade tecnológica. Contudo, suas limitações tornam-se evidentes em Big Data: esquema rígido na ingestão, escalabilidade vertical e silos de dados (INMON, 2002; STONEBRAKER; ÇETINTEMEL, 2005). Soluções modernas em nuvem (Snowflake, BigQuery, Redshift) mitigaram parte dessas limitações, mas introduzem dependência de fornecedor e custos significativos (DRECHSLER; SAUER, 2023).

2.2.2 Lago de Dados (Data Lake)

O Lago de Dados é um repositório centralizado que armazena dados em formato nativo e bruto — estruturados, semiestruturados e não estruturados —, com definição de esquema postergada para o momento do consumo, conferindo máxima flexibilidade (FANG, 2015). Entretanto, sem governança adequada, tendem a se degradar em repositórios desorganizados — pântano de dados —, decorrente da ausência de garantias transacionais e falta de versionamento (FANG, 2015; ZAHARIA et al., 2021).

2.2.3 Arquitetura Lakehouse

A arquitetura Lakehouse, formalizada por Armbrust et al. (2021), representa uma convergência das abordagens de Armazém de Dados e Lago de Dados, propondo um paradigma unificado. O Lakehouse é caracterizado por: (i) armazenamento aberto e econômico em formatos como Parquet; (ii) camada de metadados transacional com suporte a transações ACID; e (iii) desempenho analítico comparável ao Armazém de Dados, por meio de indexação, compactação e memória em cache. Essa unificação reduz redundâncias, custos operacionais e inconsistências na movimentação de dados entre sistemas distintos (ARMBRUST et al., 2021).

2.2.4 Quadro Comparativo das Arquiteturas

O Quadro 1 sintetiza as principais características das três arquiteturas, permitindo visualização objetiva das diferenças entre elas.

Quadro 1 — Comparativo entre Armazém de Dados, Lago de Dados e Lakehouse

Característica	Armazém de Dados	Lago de Dados	Lakehouse
Definição de esquema	Na ingestão	No consumo	Na ingestão c/ evolução
Tipos de dados	Estruturados	Todos	Todos
Garantias ACID	Sim (banco relacional)	Não	Sim (Delta Lake)
Custo de armazenamento	Alto	Baixo	Baixo
Escalabilidade	Vertical	Horizontal	Horizontal
Desempenho analítico	Alto	Variável	Alto
Suporte a aprendizado de máquina	Limitado	Nativo	Nativo
Versionamento de dados	Não	Não	Sim (viagem no tempo)
Dependência de fornecedor	Alta	Baixa	Baixa (formatos abertos)
Governança de dados	Madura	Imatura	Em evolução

Fonte: elaborado pelo autor com base em Armbrust et al. (2021), Fang (2015) e Zaharia et al. (2021).

2.3 Arquitetura em Camadas: Bronze, Silver e Gold

O modelo de três camadas — Bronze, Silver e Gold —, descrito por Zaharia et al. (2021), estrutura o fluxo de dados de acordo com o grau de refinamento e propósito de uso. A **camada Bronze** recebe os dados em estado bruto sem transformações, preservando o histórico completo para rastreabilidade e reprocessamento. A **camada Silver** aplica limpeza, padronização, remoção de duplicatas e validação de integridade, gerando dados confiáveis. A **camada Gold** organiza os dados refinados em modelos dimensionais otimizados para consulta — tipicamente Esquema Estrela —, alimentando ferramentas de visualização (ZAHARIA et al., 2021; KIMBALL; ROSS, 2013). Essa separação promove isolamento de falhas, controle de qualidade progressivo e rastreabilidade completa do ciclo de vida do dado.

2.4 Engenharia de Dados e Pipelines de Transformação

A Engenharia de Dados é a disciplina responsável pelo projeto, construção e manutenção de infraestruturas e pipelines para coleta, armazenamento, processamento e disponibilização de dados (VASSILIADIS, 2009). No modelo tradicional **ETL** (Extração, Transformação e Carga), os dados são transformados antes do carregamento. No modelo **ELT** (Extração, Carga e Transformação), predominante em Big Data, os dados são carregados em formato bruto e transformados posteriormente, aproveitando o processamento distribuído do ambiente analítico — modelo natural na arquitetura Lakehouse (VASSILIADIS, 2009).

2.5 Modelagem Dimensional

A modelagem dimensional, sistematizada em Kimball e Ross (2013), organiza os dados de forma intuitiva para usuários de negócio e otimizada para ferramentas de Processamento Analítico Online (OLAP). Seus elementos fundamentais são: a **tabela fato**, que registra métricas mensuráveis de transações de negócio, e as **tabelas dimensão**, que fornecem contexto descritivo respondendo às perguntas quem, o quê, quando e onde. O **Esquema Estrela (Star Schema)** conecta a tabela fato diretamente às dimensões por chaves, maximizando o desempenho analítico. Neste trabalho, a camada Gold implementará um Esquema Estrela com fato de vendas e dimensões de cliente, produto, tempo e categoria.

2.6 Qualidade de Dados

A qualidade de dados é um atributo multidimensional que reflete o grau em que os dados atendem aos requisitos de uso. Vassiliadis (2009) identifica as dimensões relevantes: **completude** (proporção de campos preenchidos), **consistência** (ausência de contradições), **acurácia** (conformidade com a realidade), **unicidade** (ausência de

duplicatas) e **pontualidade** (disponibilidade no momento necessário). Em arquiteturas Lakehouse, a qualidade é gerenciada progressivamente pelas camadas (ZAHARIA et al., 2021). Neste trabalho, completude ($\geq 95\%$) e consistência entre camadas ($\geq 98\%$) são os critérios mensuráveis de avaliação.

2.7 Ferramentas e Tecnologias

2.7.1 Apache Spark

O Apache Spark é um arcabouço de processamento distribuído de dados em larga escala, descrito por Zaharia et al. (2016) como um motor unificado para Big Data, capaz de executar cargas em lote, fluxo contínuo, SQL, aprendizado de máquina e processamento de grafos. Sua principal vantagem é o processamento em memória, que reduz a latência em cargas iterativas. No contexto deste trabalho, é a principal ferramenta de transformação entre as camadas Bronze, Silver e Gold, com integração nativa com o Delta Lake.

2.7.2 Delta Lake

O Delta Lake é uma camada de armazenamento de código aberto que adiciona garantias ACID ao armazenamento em arquivos Parquet. Zaharia et al. (2021) descrevem-no como a solução para os principais desafios do Lago de Dados: ausência de transações, inconsistência em leituras concorrentes e falta de versionamento. Suas funcionalidades incluem: **transações ACID** (atomicidade, consistência, isolamento e durabilidade); **viagem no tempo** (acesso a versões históricas por instantâneos); e **aplicação e evolução de esquema** (validação automática e evolução controlada).

2.7.3 Microsoft Power BI

O Microsoft Power BI é uma plataforma de Inteligência de Negócios para criação de relatórios e painéis interativos. Utilizado como camada de consumo da camada Gold, transforma os dados modelados dimensionalmente em visualizações acessíveis a usuários de negócio. Sua integração com fontes Parquet e Delta Lake o torna adequado para validação dos indicadores analíticos gerados pelo pipeline proposto (MICROSOFT, 2023).

CAPÍTULO 3 — METODOLOGIA

3.1 Classificação da Pesquisa

Do ponto de vista de sua natureza, este trabalho configura-se como **pesquisa aplicada**, pois objetiva a solução de um problema prático concreto: a implementação de uma arquitetura de dados funcional para análise de comércio eletrônico (GIL, 2002). Quanto aos seus objetivos, classifica-se como **exploratório-descritiva**: exploratória pela escassez de estudos aplicados que combinem arquitetura Lakehouse e validação empírica no domínio de comércio eletrônico; descritiva por registrar sistematicamente as características do pipeline e seus resultados mensuráveis.

Em relação à abordagem, a pesquisa é **mista (quali-quantitativa)**: utiliza instrumentos quantitativos para métricas de desempenho e qualidade, e abordagem qualitativa para análise comparativa entre as arquiteturas. Quanto ao procedimento técnico, enquadra-se como **estudo de caso experimental**, pois implementa um sistema de software completo e avalia seus resultados em condições controladas (YIN, 2015).

3.2 Ambiente de Desenvolvimento

A implementação é realizada em ambiente local (Microsoft Windows 11 Pro), com mínimo de 8 GB de memória RAM, executando o Apache Spark em modo local para simular um ambiente realista de organizações de pequeno e médio porte.

Quadro 2 — Ferramentas e versões utilizadas

Ferramenta	Versão	Finalidade
Python	3.11	Linguagem principal do projeto
Apache Spark	3.5.1	Processamento distribuído entre camadas
Delta Lake	3.2.0	Armazenamento transacional ACID
FastAPI	0.115.0	Interface de programação simuladora de comércio eletrônico
Pandas	2.2.2	Manipulação de dados tabulares
PyArrow	17.0.0	Serialização no formato Parquet
Faker	26.0.0	Geração de dados sintéticos
PostgreSQL	15+	Banco do Armazém de Dados de referência
SQLAlchemy	2.0+	Conexão Python com PostgreSQL
Power BI Desktop	Versão atual	Camada de visualização analítica

Fonte: elaborado pelo autor.

3.3 Especificação do Conjunto de Dados Simulado

Os dados são inteiramente sintéticos, gerados por interface de programação desenvolvida com FastAPI e populada pela biblioteca Faker, garantindo controle total sobre volume e qualidade, além de conformidade com a Lei Geral de Proteção de Dados (LGPD). O conjunto de dados simula 24 meses de operação de uma plataforma de comércio eletrônico fictícia.

Quadro 3 — Entidades e volumes do conjunto de dados simulado

Entidade	Volume	Descrição
Clientes	1.000	Dados cadastrais com cidade, estado, região e segmento
Categorias	20	Hierarquia de categorias de produtos
Produtos	500	Catálogo com preço, categoria e disponibilidade
Pedidos	10.000	Cabeçalho com status e canal de venda
Itens de Pedido	~30.000	Produto, quantidade e desconto por linha
Pagamentos	10.000	Método, status e data de pagamento

Fonte: elaborado pelo autor.

Para tornar o cenário realista, o conjunto de dados introduz intencionalmente imperfeições: 5% dos clientes com campos nulos; 3% dos itens com valores negativos; 2% dos pedidos duplicados; 1% dos pagamentos com datas inválidas. Essas imperfeições validam as regras de qualidade da camada Silver e permitem mensurar os critérios da hipótese.

3.4 Arquitetura do Pipeline de Dados

Camada Bronze — ingestão via requisição HTTP dos recursos da interface de programação, sem transformações, com metadados de rastreabilidade (data de ingestão, origem), particionada por data em `data/bronze/{entidade}/`. **Camada Silver** — remoção de duplicatas, validação de domínio, padronização de tipos, normalização de cadeias de texto e geração de campos derivados, em `data/silver/{entidade}/`. **Camada Gold** — construção do Esquema Estrela com chaves substitutas e gravação em `data/gold/{tabela}/`, com exportação para Power BI.

3.5 Modelo Dimensional — Esquema Estrela

Quadro 4 — Tabela Fato: fato_vendas

Coluna	Tipo	Descrição
id_fato	BIGINT	Chave substituta
id_cliente	INT	Chave estrangeira → dim_cliente

Coluna	Tipo	Descrição
id_produto	INT	Chave estrangeira → dim_produto
id_tempo	INT	Chave estrangeira → dim_tempo
id_categoria	INT	Chave estrangeira → dim_categoria
id_pedido	STRING	Chave de negócio do pedido
quantidade	INT	Itens vendidos
valor_bruto	DECIMAL(10,2)	Valor sem desconto
desconto	DECIMAL(10,2)	Desconto aplicado
valor_liquido	DECIMAL(10,2)	Valor final da venda
metodo_pagamento	STRING	Forma de pagamento utilizada

Fonte: elaborado pelo autor.

As tabelas dimensão são: **dim_cliente** (identificador, nome, cidade, estado, região, segmento); **dim_produto** (identificador, nome, preço unitário, categoria); **dim_tempo** (identificador AAAAMMDD, data, dia, mês, trimestre, ano, dia da semana, indicador de fim de semana); e **dim_categoria** (identificador, nome, descrição).

3.6 Modelo de Referência — Armazém de Dados Convencional

Para comparação empírica, é implementado um Armazém de Dados de referência em PostgreSQL, carregado via processo ETL com Pandas e SQLAlchemy, sem particionamento Delta, sem viagem no tempo e sem otimização ACID avançada. Adota o mesmo Esquema Estrela da camada Gold, isolando as diferenças arquiteturais como variável de comparação.

Quadro 5 — Diferenças entre Lakehouse e Armazém de Dados de Referência

Característica	Lakehouse (Delta Lake)	Armazém de Dados (PostgreSQL)
Armazenamento	Parquet + Registro Delta	Tabelas relacionais em disco
Garantias ACID	Nativas (Delta Lake)	Nativas (PostgreSQL)
Esquema	Evolução controlada	Rígido (DDL explícito)
Particionamento	Automático por coluna	Manual (índices)
Integração com Aprendizado de Máquina	Nativa (Spark)	Via exportação externa
Versionamento	Viagem no tempo nativa	Inexistente
Escalabilidade	Horizontal	Vertical

Fonte: elaborado pelo autor.

3.7 Protocolo de Avaliação

Quadro 6 — Métricas de qualidade e critérios de aceitação

Métrica	Fórmula	Critério
Compleitude	$\text{registros_completos} / \text{total_esperado} \times 100$	$\geq 95\%$
Consistência	$\text{registros_íntegros} / \text{total_bronze} \times 100$	$\geq 98\%$
Unicidade	$(\text{total} - \text{duplicatas}) / \text{total} \times 100$	$= 100\%$
Acurácia de tipos	$\text{campos_tipados_corretamente} / \text{total} \times 100$	$= 100\%$

Fonte: elaborado pelo autor com base em Vassiliadis (2009).

A latência de consulta é medida com cronômetro em Python e pela interface de monitoramento do Spark, com critério de aceitação: Lakehouse responde em tempo inferior ou igual a $1,5\times$ o tempo do PostgreSQL para as mesmas cinco consultas analíticas. Os **cinco indicadores de negócio** avaliados são: (1) receita total por período; (2) valor médio de pedido por cliente e região; (3) dez produtos mais vendidos por receita e volume; (4) taxa de desconto médio por categoria; (5) distribuição de formas de pagamento por período.

3.8 Cronograma de Execução

Quadro 7 — Cronograma do projeto

Etapa	Atividade	Período
1	Revisão bibliográfica e fundamentação teórica	Março 2026
2	Projeto da interface de programação simuladora e do Esquema Estrela	Abril 2026
3	Implementação da interface e camada Bronze	Abril 2026
4	Implementação da camada Silver	Mai 2026
5	Implementação da camada Gold (Esquema Estrela)	Mai 2026
6	Implementação do Armazém de Dados de referência (PostgreSQL)	Mai 2026
7	Desenvolvimento do painel Power BI	Junho 2026
8	Coleta e análise das métricas de avaliação	Junho 2026
9	Redação dos capítulos de resultados e conclusões	Julho 2026
10	Revisão final e entrega do TCC	Agosto 2026

Fonte: elaborado pelo autor.

REFERÊNCIAS BIBLIOGRÁFICAS

- ARMBRUST, Michael et al.** Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics. In: Conference on Innovative Data Systems Research (CIDR), 2021.
- CHEN, Min; MAO, Shiwen; LIU, Yunhao.** Big Data: A Survey. Mobile Networks and Applications, v. 19, n. 2, p. 171–209, 2014.
- DRECHSLER, Gunnar; SAUER, Stefan.** Cloud Data Warehousing: Challenges and Opportunities. Journal of Database Management, v. 34, n. 1, p. 1–25, 2023.
- FANG, Hu.** Managing Data Lakes in Big Data Era: What's a Data Lake and Why Has It Became Popular in Data Management Ecosystem. In: IEEE International Conference on Cyber Technology in Automation, Control, and Intelligent Systems (CYBER), 2015.
- GIL, Antonio Carlos.** Como elaborar projetos de pesquisa. 6. ed. São Paulo: Atlas, 2002.
- INMON, William H.** Building the Data Warehouse. 4. ed. Nova York: John Wiley & Sons, 2002.
- KIMBALL, Ralph; ROSS, Margy.** The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling. 3. ed. Indianápolis: John Wiley & Sons, 2013.
- LANEY, Doug.** 3D Data Management: Controlling Data Volume, Velocity, and Variety. META Group Research Note, 2001.
- MICROSOFT.** Power BI Documentation. Microsoft Docs, 2023. Nota: fonte técnica primária de ferramenta de mercado.
- STONEBRAKER, Michael; ÇETINTEMEL, Ugur.** One Size Fits All: An Idea Whose Time Has Come and Gone. In: Proceedings of the 21st International Conference on Data Engineering (ICDE), 2005.
- VASSILIADIS, Panos.** A Survey of Extract-Transform-Load Technology. International Journal of Data Warehousing and Mining, v. 5, n. 3, p. 1–27, 2009.
- ZAHARIA, Matei et al.** Apache Spark: A Unified Engine for Big Data Processing. Communications of the ACM, v. 59, n. 11, p. 56–65, 2016.
- ZAHARIA, Matei et al.** Delta Lake: High-Performance ACID Table Storage over Cloud Object Stores. Proceedings of the VLDB Endowment, v. 13, n. 12, p. 3411–3424, 2021.
- YIN, Robert K.** Estudo de caso: planejamento e métodos. 5. ed. Porto Alegre: Bookman, 2015.