

Implementação de uma arquitetura Lakehouse com camadas Bronze, Silver e Gold e modelagem dimensional para análise de dados escalável

Este trabalho propõe a implementação de uma arquitetura Lakehouse baseada no padrão de camadas Bronze, Silver e Gold, com o objetivo de possibilitar o armazenamento, processamento e análise escalável de grandes volumes de dados, integrando conceitos de Engenharia de Dados, Big Data e Business Intelligence.

A arquitetura Lakehouse combina características de Data Lakes e Data Warehouses, permitindo armazenar dados brutos de forma econômica e flexível, ao mesmo tempo em que oferece estruturas otimizadas para consultas analíticas. Nesse contexto, será desenvolvido um pipeline de dados responsável pela ingestão de múltiplas fontes na camada Bronze (dados brutos), aplicação de processos de limpeza, padronização e validação na camada Silver (dados tratados) e, por fim, organização analítica na camada Gold, onde os dados serão modelados dimensionalmente por meio de tabelas fato e dimensões no formato Star Schema.

O processamento e transformação dos dados serão realizados com tecnologias de engenharia de dados, como Apache Spark ou Python, enquanto o armazenamento seguirá o padrão transacional de tabelas analíticas com suporte a versionamento, utilizando soluções como Delta Lake. A orquestração dos pipelines garantirá automação, rastreabilidade e escalabilidade do fluxo de dados.

Na camada Gold, será implementado um modelo dimensional para suporte à análise de indicadores de negócio, possibilitando a construção de dashboards interativos em ferramentas de BI, como Metabase ou Microsoft Power BI, permitindo a visualização de métricas, KPIs e relatórios estratégicos para apoio à tomada de decisão.

Por fim, o trabalho avaliará aspectos de desempenho, escalabilidade, organização e qualidade dos dados, comparando a arquitetura proposta com abordagens tradicionais de Data Warehouse. Espera-se demonstrar que a utilização do modelo Lakehouse oferece maior flexibilidade, menor custo de armazenamento e melhor eficiência no processamento de grandes volumes de dados, tornando-se uma alternativa viável para ambientes analíticos modernos.