

Implementação de uma arquitetura Lakehouse com camadas Bronze, Silver e Gold e modelagem dimensional para análise de dados escalável

Este trabalho propõe a implementação de uma arquitetura Lakehouse baseada no padrão de camadas Bronze, Silver e Gold, com o objetivo de possibilitar o armazenamento, processamento e análise escalável de grandes volumes de dados, integrando conceitos de Engenharia de Dados, Big Data e Business Intelligence.

A arquitetura Lakehouse combina características de Data Lakes e Data Warehouses, permitindo armazenar dados brutos de forma econômica e flexível, ao mesmo tempo em que oferece estruturas otimizadas para consultas analíticas. Nesse contexto, será desenvolvido um pipeline de dados responsável pela ingestão de múltiplas fontes na camada Bronze (dados brutos), aplicação de processos de limpeza, padronização e validação na camada Silver (dados tratados) e, por fim, organização analítica na camada Gold, onde os dados serão modelados dimensionalmente por meio de tabelas fato e dimensões no formato Star Schema.

O processamento e transformação dos dados serão realizados com tecnologias de engenharia de dados, como Apache Spark ou Python, enquanto o armazenamento seguirá o padrão transacional de tabelas analíticas com suporte a versionamento, utilizando soluções como Delta Lake. A orquestração dos pipelines garantirá automação, rastreabilidade e escalabilidade do fluxo de dados.

Na camada Gold, será implementado um modelo dimensional para suporte à análise de indicadores de negócio, possibilitando a construção de dashboards interativos em ferramentas de BI, como Metabase ou Microsoft Power BI, permitindo a visualização de métricas, KPIs e relatórios estratégicos para apoio à tomada de decisão.

Por fim, o trabalho avaliará aspectos de desempenho, escalabilidade, organização e qualidade dos dados, comparando a arquitetura proposta com abordagens tradicionais de Data Warehouse. Espera-se demonstrar que a utilização do modelo Lakehouse oferece maior flexibilidade, menor custo de armazenamento e melhor eficiência no processamento de grandes volumes de dados, tornando-se uma alternativa viável para ambientes analíticos modernos.

1 – Tema Preliminar

Implementação de uma arquitetura Lakehouse com camadas Bronze, Silver e Gold e modelagem dimensional para análise de dados escalável.

Este trabalho tem como objetivo implementar uma arquitetura moderna de dados baseada no conceito de Lakehouse, estruturada em três camadas principais: Bronze, Silver e Gold, com o propósito de demonstrar na prática um pipeline completo de engenharia de dados voltado para análise de informações.

A base de dados utilizada no projeto será disponibilizada por meio de uma API desenvolvida especificamente para o trabalho, simulando um sistema transacional que fornece dados de negócio. A API será responsável por expor os dados por meio de endpoints que permitirão a extração automatizada das informações.

O processo de ingestão realizará a coleta desses dados e os armazenará inicialmente na camada Bronze da arquitetura Lakehouse. Nessa etapa, os dados serão armazenados em seu formato bruto, preservando as informações exatamente como foram obtidas da fonte de origem, garantindo rastreabilidade e histórico dos dados.

Na camada Silver serão aplicados processos de transformação e tratamento das informações. Essa etapa envolverá limpeza de dados, padronização de formatos, remoção de inconsistências, validação de registros e organização estrutural das tabelas. O processamento dos dados será realizado utilizando Python e tecnologias de processamento de dados como Apache Spark, permitindo manipulação eficiente de grandes volumes de informação.

Após o tratamento dos dados, será construída a camada Gold, que representa a camada analítica da arquitetura. Nessa etapa os dados serão organizados em um modelo dimensional composto por tabelas fato e dimensões estruturadas no formato Star Schema. Essa modelagem será projetada para suportar consultas analíticas e facilitar a geração de indicadores de negócio.

Como resultado final do pipeline, os dados estruturados na camada Gold serão utilizados na construção de dashboards analíticos em Power BI. Será desenvolvido um arquivo PBIX contendo visualizações interativas e indicadores de desempenho que demonstram o processo de transformação de dados brutos em informações estratégicas.

Dessa forma, o projeto apresenta a implementação completa de um fluxo moderno de engenharia de dados, desde a extração dos dados até a geração de indicadores analíticos.

2 – Área de Aplicação

O trabalho está inserido na área de Ciência de Dados, Engenharia de Dados e Business Intelligence, com foco na construção de arquiteturas modernas para processamento e análise de dados em larga escala.

A arquitetura Lakehouse implementada no projeto representa um modelo amplamente utilizado em ambientes corporativos que lidam com grandes volumes de dados provenientes de múltiplas fontes. O pipeline desenvolvido contempla as principais etapas da engenharia de dados, incluindo ingestão, armazenamento, transformação, modelagem analítica e visualização de dados.

O projeto demonstra a aplicação prática de conceitos fundamentais da área de dados, como pipelines de dados, arquitetura em camadas, modelagem dimensional e construção de indicadores analíticos. Além disso, a utilização de tecnologias modernas de processamento e armazenamento de dados contribui para simular um ambiente próximo ao encontrado em empresas que trabalham com Big Data e análise de dados.

A integração entre engenharia de dados e ferramentas de Business Intelligence possibilita transformar dados operacionais em informações estratégicas, permitindo que gestores e analistas compreendam o desempenho de processos por meio de indicadores e dashboards interativos.

3 – Justificativa Informal

Com o crescimento acelerado da geração de dados em sistemas digitais, tornou-se essencial adotar arquiteturas capazes de armazenar, processar e analisar grandes volumes de informações de forma eficiente. Modelos tradicionais de armazenamento de dados nem sempre conseguem atender às necessidades atuais de escalabilidade, flexibilidade e integração entre diferentes tipos de dados.

Nesse contexto, a arquitetura Lakehouse surge como uma abordagem moderna que combina as vantagens de Data Lakes e Data Warehouses. Essa arquitetura permite armazenar dados brutos de forma econômica e flexível, ao mesmo tempo em que oferece estruturas organizadas para análises analíticas.

A implementação da arquitetura em camadas Bronze, Silver e Gold contribui para organizar o fluxo de dados de forma estruturada. A camada Bronze preserva os dados originais, garantindo histórico e rastreabilidade. A camada Silver realiza os processos de limpeza e padronização, garantindo qualidade e consistência das

informações. Já a camada Gold disponibiliza os dados organizados em um modelo dimensional otimizado para análises.

Além disso, a utilização de uma API desenvolvida especificamente para o projeto permite simular um cenário real de ingestão de dados provenientes de sistemas externos. Essa abordagem demonstra como dados podem ser coletados de forma automatizada e integrados a um pipeline de engenharia de dados.

Por fim, a construção de dashboards no Power BI permite apresentar os resultados do pipeline de forma visual e interativa, evidenciando como os dados processados podem ser utilizados para gerar indicadores de desempenho e apoiar processos de tomada de decisão.

Dessa forma, o trabalho demonstra na prática a aplicação de conceitos modernos de engenharia de dados e Business Intelligence, evidenciando a importância de arquiteturas escaláveis para o tratamento e análise de dados em ambientes analíticos.